

TERCER INFORME: ULTIMACIÓ D'OBJECTIUS I REALITZACIÓ DELS MODELS PREDICTIUS

1. Introducció

En aquest tercer informe s'explica com s'han dut a terme els objectius inicials que encara teníem pendents, i també s'expliquen els models realitzats per poder predir l'abandonament dels clients de la companyia de telecomunicacions, ja que l'objectiu de la companyia ha de ser precisament evitar aquests abandonaments. Concretament es fan 3 models predictius:

- Regressió Logística: s'utilitza per predir valors binaris. Funciona estimant la probabilitat que una observació pertanyi a una de les dues classes possibles, mitjançant una combinació lineal de les variables d'entrada. Tot i que el nom suggereix una relació amb la regressió lineal, en realitat és un model de classificació. És útil quan volem entendre com cada variable afecta la el que volem predir.
- k-nearest neighbor prediction: aquest model (KNN) calcula la predicció per un nou punt mesurant la distància fins als k punts més propers del conjunt de training que s'utilitza per fer el model, com s'explica més endavant.
- Arbre de decisió: aquest algoritme crea una estructura en forma d'arbre on cada node representa una pregunta sobre una de les variables del conjunt de dades. A partir de les respostes, les observacions es van dividint en branques fins arribar a una predicció final. És un model fàcil d'interpretar i útil per detectar patrons de decisió.

Finalment es comparen els 3 models per obtenir-ne conclusions de quin/s sembla millor.

2. Últims objectius


2.1 Objectiu mesos d'estada i abandonament: aprofundiment i millora

Arran d'una crítica constructiva durant la nostra segona presentació a aquest objectiu, on vèiem si hi havia alguna influència entre la durada a la companyia, els preus a pagar durant aquesta durada i l'abandonament, vam decidir millorar-lo i aprofundir una mica més en funció de les indicacions donades pel nostre professor.

El problema estava en el fet que les conclusions extretes mancaven una mica de justificacions. Vam veure que en funció del temps els preus pujaven i que a l'hora la taxa d'abandonament baixava i sense pensar-ho vam relacionar aquests dos fets immediatament. No vam pensar en cap altra alternativa ni en perquè realment aquests preus pujaven ni en perquè la taxa d'abandonament baixava. Tampoc vam arribar al nucli de la qüestió que era veure sí el fet d'haver estat pagant quotes molt elevades durant molt de temps influïa en l'abandonament.

- Per què pugen els preus al llarg del temps?



Primer vam començar en veure perquè apujaven els preus al llarg del temps i se'ns va ocórrer que podia ser perquè els clients cada cop contractaven més serveis i ens vam focalitzar en aquest aspecte. Per veure aquesta relació vam haver d'editar una mica els dataframes. Vam agafar l'arxiu CSV "internet.csv" on es troben tots els possibles serveis contractats pels clients i per a cada un vam fer un recompte dels serveis contractats i els vam afegir en una nova columna al dataframe, després vam exportar aquesta columna a l'arxiu CSV "abandonament_editat.csv" on es troben les despeses mensuals i el ternure (estança a la companyia) per poder veure la influència més fàcilment. Per últim vam representar en funció dels mesos de permanència, la mitjana dels costos mensuals i la mitjana de serveis contractats. Els resultats van ser els següents:



Com es pot apreciar, es veu clarament que la mitja de serveis contractats augmenta també amb la mitja de despeses mensuals i, per tant, havíem trobat de forma fiable almenys un dels motius pel qual els preus al llarg del temps pujaven. Podíem afirmar que ho fan perquè els clients cada cop contracten més serveis i això òbviament té una repercussió econòmica.

- Com influeix haver estat pagant elevats costos durant molt de temps i l'abandonament?


Després d'haver solucionat el primer apartat ens vam posar amb la segona qüestió que era veure quina influència té el fet d'haver estat pagant certes quotes mensuals al llarg de molt temps i l'abandonament. Per aconseguir-ho vam dividir els dataframes en dos grups, aquells que han abandonat i aquells que no i de cada grup vam veure com es comportaven les despeses mensuals al llarg del temps. Els resultats obtinguts van ser els següents:



Com es pot observar, en els dos casos els preus mensuals han anat creixent al llarg del temps, però en el cas d'aquells que han abandonat el preu a pagar mes a mes ha estat més elevat sempre. Això ens fa pensar que efectivament el fet d'haver estat pagant preus elevats durant molt de temps fa que els clients tendixin a abandonar la companyia de telecomunicacions.


2.2. Influència del mètode de pagament en l'abandonament

Un dels objectius pendents era el de veure si hi havia algun tipus d'influència en el mètode de pagament dels clients i el seu abandonament a la companyia de telecomunicacions. L'objectiu tal com es pot intuir, no ha tingut massa complicació. Vam agrupar les dades del fitxer CSV on es troba aquesta variable ("abandonament.CSV") segons el mètode de pagament fent servir el "gropuby()". Després de cada grup, vam calcular la taxa d'abandonament per veure les tendències. Aquesta taxa d'abandonament consisteix en el tant per cent d'abandonaments a cada grup. Els resultats van ser els següents:



Com es pot observar, clarament aquells que fan el pagament amb xec electrònic tendeixen a abandonar més la companyia de telecomunicacions. Quasi un 50% de clients que efectuen aquest mètode de pagament acaben abandonant la companyia. En canvi, la resta de mètodes de pagament tenen una taxa d'abandonament baixa i bastant igualada, entorn del 17%.

Després de veure aquesta clara tendència vam aprofitar un altre variable per continuar aquest estudi. A l'anàlisi del fitxer "abandonament.csv" vam crear una nova columna on classificàvem als clients segons si el seu mètode de pagament era automàtic o no. Entenem per automàtic que tu no fas la transacció directament sinó que cada mes et van cobrant automàticament. Doncs vam agafar aquesta nova variable i vam veure quina taxa d'abandonament tenia per aprofundir més en la influència del mètode de pagament i la permanència a la companyia. Els resultats obtinguts van ser els següents:



Com es pot observar aquells que no fan un pagament automàtic tendeixen a abandonar més la companyia de telecomunicacions que aquells que si paguen d'aquesta forma. Per ser sincers, el resultat era d'esperar, ja que si ens fixem en l'apartat anterior a aquest, el mètode de pagament amb més taxa d'abandonament i amb diferència era el txec electrònic el qual no es fa de forma automàtica. Per tant, es podia predir que els mètodes de pagament no automàtics en general tinguessin una taxa major.

Per últim, també vam fer una petita interpretació dels resultats obtinguts a aquest objectiu. Creiem que aquells que paguen de forma "manual" tenen una major tendència a l'abandonament perquè a l'haver de, mes a mes, efectuar el pagament de forma conscient tenen més present el preu que paguen i tendeixen a pensar més en

què igual estan pagant de més per estar a la companyia i que no els beneficia gaire. En canvi, aquells que paguen automàticament no són tan conscients dels preus que paguen i no es fan tantes preguntes com els altres.

Una possible mesura per reduir l'abandonament per part d'aquells que paguen de forma manual podria ser reduir una mica els costos mensuals d'aquests mitjançant ofertes i de més.

2.3. Anàlisi estadístic de les relacions trobades anteriorment

Seguint amb l'anàlisi de les característiques dels clients segons la seva demografia, hem utilitzat diverses proves estadístiques per veure quines característiques són verdaderament rellevants en aquestes relacions. Això ens ha permès simplificar els gràfics i que siguin més visuals perquè hem pogut eliminar les variables que no tenien un impacte significatiu.


- Relació característiques demogràfiques amb serveis contractats:

Hem creat una nova variable que representa el nombre de serveis que ha contractat un client perquè creiem que pot tenir una influència important en l'abandonament i ens pot ser útil a l'hora d'extreure conclusions sobre els clients. Per crear aquesta nova variable, hem sumat totes les columnes de serveis que tenien 'Yes' de cada client i si tenien algun tipus de servei d'internet o telefònic contractat.

Hem realitzat un t-test de Welch per veure si les mitjanes de total_serveis diferien significativament segons les categories: seniors, genere, dependents i parella. Aquest test és una versió modificada de la prova de la t-Student, que ens permet comparar mitjanes de dos grups. El t-test de Welch però ens permetrà comparar dos grups de dades que no tinguin variàncies iguals, cosa que no podem fer amb el test t-Student. Els resultats obtinguts en el test han estat els següents

Grups	mitjana 0	mitjana 1	Δ mitjanes	p-valor
SeniorCitizen (1/0)	3.11	3.85	0.74	0.000...
gender (1/0)	3.25	3.21	-0.04	0.507...
Partner (1/0)	2.80	3.70	0.9	0.000...
Dependents (1/0)	3.24	3.21	-0.04	0.594...

Si utilitzem un valor de significació (p-valor) de < 0.05 , podem dir que les variables SeniorCitizen i Partner tenen una relació estadísticament significativa amb el nombre de serveis contractats, mentre que gender i Dependents no. Aquesta tendència es pot observar també en el gràfic, que mostra la mitjana de serveis contractats segons la situació de parella i si el client és sènior o no. Veiem que, tant per als clients amb parella com per als que no en tenen, els sèniors contracten de mitjana més serveis que els no sèniors (+ 0.7 serveis de mitjana). A més, els clients amb parella també solen contractar més serveis que els que no en tenen (0.9 serveis més de mitjana).




- Anàlisi de la permanència (tenure) segons variables demogràfiques

Per fer-ho, hem tornat a aplicar el test de Welch per comparar les mitjanes del 'tenure' entre els dos grups de cada variable. Els resultats mostren que, mentre que la diferència entre homes i dones o entre persones grans i no grans és molt petita i no significativa (amb p-valors de 0,334 i 0,118 respectivament), les diferències entre tenir o no parella i tenir o no dependents són significatives des del punt de vista estadístic. En concret, els clients amb parella tenen una mitjana de 18.68 mesos superior als que no en tenen. També observem que els que tenen dependents presenten una mitjana de 38,33 mesos, davant dels 29,68 dels que no en tenen.

Grups	mitjana 0	mitjana 1	Δ mitjanes	p-valor
SeniorCitizen (1/0)	32.06	33.35	+1.28	0.118
gender (1/0)	31.97	32.57	+0.60	0.334
Partner (1/0)	23.22	41.91	+18.68	0.000...
Dependents (1/0)	29.68	38.33	+8.66	0.000...

Per complementar aquesta anàlisi, s'ha representat gràficament la distribució del tenure mitjançant un gràfic de densitat KDE, on s'han comparat les distribucions segons si el client té parella i si té dependents. Perquè la densitat no s'estengui cap a valors negatius (cosa que no tindria sentit si parlem de permanència en mesos), s'ha limitat el domini del gràfic a valors positius. Aquesta visualització mostra clarament com els clients amb parella presenten una distribució de permanència desplaçada cap a valors més alts. En canvi, pel que fa als dependents, la diferència entre tenir-ne o no és més marcada entre els clients sense parella, mentre que en els clients que ja en tenen, les distribucions són gairebé iguals.

Distribució del temps de permanència segons parella i dependents



En conclusió, veiem que tenir parella és una variable demogràfica clarament associada amb una permanència més llarga a l'empresa. Pel contrari, tot i que el test de Welch anterior indicava una diferència mitjana estadísticament significativa entre tenir o no dependents, hem vist en el gràfic que tenir o no persones a càrrec no sembla tenir gaire efecte addicional sobre la permanència.

3. Models predictius

3.1 Preparació de les dades

Per tal de fer els models predictius, primerament es van ajuntar en un mateix fitxer 'csv' totes les 3 taules a partir de la columna dell 'Customer ID', que posteriorment es va eliminar ja que no seria de més utilitat.

La variable a predir és l'anomenada 'Churn' que si té valor 1 ('Yes') és que el client en qüestió abandona la companyia, i si té valor 0 ('No') és que no ho fa. Per tant es separa la variable a predir que anomenarem y, de les que ens permetran predir-la, que anomenarem X.

Després, es va comprovar que no hi haguessin duplicats i es van modificar les dades per tal que fossin aptes pels models a utilitzar, pel quals és essencial que totes les variables categòriques fossin numèriques, ja que la majoria de models no poden funcionar directament amb elles. Per això, vam codificar variables com gender, Partner, Dependents, o InternetService, que inicialment tenien valors com "Male", "Yes", "DSL", etc. En el cas de les variables amb dues categories, les vam convertir en variables binàries (per exemple, gender: 0 per "Female" i 1 per "Male"). Quan una variable tenia més de dues categories (com InternetService o Contract), vam generar una nova columna per a cada categoria i indicant amb 0 o 1 si es complia o no. Si dues de les columnes resultants transmetien exactament la mateixa informació que una altra, es prescindia d'aquesta última, ja que no interessa tenir diferents columnes per una mateixa informació.

3.2 Dificultats trobades durant la realització dels models

Durant les sessions a classe ens vam trobar amb el problema de que els models predictius ens donaven diferents si executàvem el codi en els ordinadors de la universitat o en els nostres quan treballàvem des de casa, segurament degut a algun factor 'random' que no controlàvem. Com que als 3 integrants del grup ens passava el mateix, després de consultar-ho amb el professor, el que vam decidir fer va ser descarregar-nos els fitxers de X i y, 'training' i 'test', en format '.csv' des de l'ordinador de la universitat i fer servir aquests també des dels nostres portàtils els 3 integrants del grup.

3.3 Regressió logística

Per crear i entrenar un model de regressió logística, hem utilitzat la funció 'LogisticRegression' de 'scikit-learn'. Un dels paràmetres més importants és la C, que controla la regularització del model. Aquesta regularització serveix per evitar que el model s'ajusti massa a les dades d'entrenament. Com que la C és l'invers de la força de regularització, valors petits de C generen models més prudents, i valors alts models que confien més en les dades d'entrenament. Per estudiar com afecta aquest paràmetre, hem provat diversos valors de C que van des de 10^{-3} fins a 10^3 , en potències de 10. Això ens permet veure com canvia el rendiment del model segons el grau de regularització. Un altre

paràmetre que hem variat ha estat el d'iteracions màximes (max_iter) però hem vist que per qualsevol número prou gran no tenia cap influència en els resultats del model.

Per avaluar el rendiment, hem observat dues mètriques: l'exactitud (accuracy) i el recall. L'exactitud ens indica quin percentatge de prediccions són correctes, mentre que el recall ens diu quants dels casos de churn reals hem estat capaços d'identificar. Hem vist que amb $C = 10$, obtenim els millors resultats amb una exactitud de 79.63% i un recall del 50.26%. Això vol dir que el model identifica correctament gairebé 8 de cada 10 clients en general, però només detecta 1 de cada 2 casos de churn.

	precision	recall	f1-score	support
0	0.83	0.90	0.87	1035
1	0.65	0.50	0.57	374
accuracy			0.80	1409
macro avg	0.74	0.70	0.72	1409
weighted avg	0.79	0.80	0.79	1409

Taula: Classification Report per el model amb $C=10$

Una característica interessant de la regressió logística és que podem analitzar els coeficients del model, que ens indiquen com afecta cada variable a la probabilitat de churn. Un coeficient positiu implica que, a mesura que augmenta el valor d'aquella variable, també ho fa la probabilitat que el client abandoni l'empresa. En canvi, un coeficient negatiu indica que aquella característica està associada amb una menor probabilitat d'abandonament. La següent taula és el valor dels coeficients ordenats del model que regressió logística que rendeix millor (és la que té una $C=10$)

Feature	Coefficient
totalcharges_scaled	1.634396
InternetService_Fiber optic	0.994792
PaymentMethod_Electronic check	0.352826
StreamingMovies	0.339801
PaperlessBilling	0.335674
MultipleLines_Yes	0.262860
SeniorCitizen	0.237313
StreamingTV	0.232836
MultipleLines_No phone service	0.166950
DeviceProtection	0.012114
PaymentMethod_Mailed check	-0.005592
gender	-0.015313
Partner_Yes	-0.048258
PaymentMethod_Credit card (automatic)	-0.050299
OnlineBackup	-0.074056
Dependents	-0.118807
PhoneService	-0.174838
Partner_nan	-0.277920
OnlineSecurity	-0.310114
TechSupport	-0.311513
Contract_One year	-0.665852
monthlycharges_scaled	-0.743521
InternetService_No	-0.969128
Contract_Two year	-1.354865
tenure_scaled	-3.422916

Entre les variables amb més pes dins el model trobem la variable TotalCharges_charges_scaled, és a dir la variable normalitzada del que ha pagat el client durant tot el temps que ha estat a l'empresa i InternetService_FiberOptic que són clients que han contractat el servei de fibra òptica. Pel contrari els coeficients negatius més alts, que es relacionen amb un abandonament més baix, han sigut la variable normalitzada de la permanència (tenure_scaled), i Contract_TwoYear que són els clients que tenen un contracte de dos anys.

Finalment, hem fet una prova per veure com afecta l'eliminació de variables amb un pes molt baix dins del model ('Coefficient' < 0.1). Quan traiem aquestes variables com el gènere o Partner_Yes, el recall baixa encara més, fet que demostra que aquestes característiques, per insignificants que semblen són importants per detectar clients amb risc d'abandonament. En aquest cas el model de regressió logística perd capacitat predictiva, i identifica menys casos de churn. Més endavant comprovarem la influència d'aquests coeficients amb els resultats dels altres models que hem utilitzat.

	precision	recall	f1-score	support
0	0.83	0.91	0.87	1035
1	0.65	0.49	0.56	374
accuracy			0.79	1409
macro avg	0.74	0.70	0.71	1409
weighted avg	0.78	0.79	0.78	1409

Taula: Classification Report per el model amb C=10 i eliminant les variables predictores menys importants

En conclusió, la regressió logística ens permet no només fer prediccions amb força precisió, sinó també entendre quins factors contribueixen més a la pèrdua de clients. Tot i això, cal tenir en compte que té molt bon rendiment a l'hora de predir els clients que no abandonen, però en canvi, té més dificultats per identificar correctament els clients que sí que abandonen, cosa que significa que la meitat dels abandonaments reals no són detectats. Això es pot deure a que els clients que no abandonen representen aproximadament un 70 % del total de dades i per tant el model és entrenat amb molts més casos de clients fidels que clients que han abandonat. Aquesta sobrerepresentació fa que el model tendeixi a encertar sobretot en aquests casos, augmentant l'exactitud global.

Per tant, encara que la regressió logística sigui útil per a l'anàlisi i interpretació dels factors de risc, també seria bona idea provar altres models per millorar la precisió a l'hora de predir els casos d'abandonament.

3.4 k-nearest neighbor prediction (KNN)

Evidentment per tal de realitzar el model de predicció "k-nearest neighbor prediction" (en el notebook 'k-nearest_neighbor_prediction(4A)'), primerament es va fer el que s'explica en l'apartat 3.1 i es va tenir en compte el que s'indica a l'apartat 3.2.

Ara bé, per aquest tipus de model predictiu, però, cal destacar el següent: vam comprovar que pel mètode de la Regressió Logística semblava que el fet de "fixar" els fitxers training i test arreglava el problema comentat a l'apartat 3.2, però pel mètode de la "k-nearest neighbor prediction", quan es fa el codi no es pot fixar un random_state (per tal d'establir l'estat inicial dels processos aleatoris interns i així evitar possibles resultats diferents cada vegada que s'executi el codi), i això pot fer que segueixi havent-hi problemes. Per aquest motiu, en aquest notebook s'hi han afegit altres mesures, obtingudes amb el ChatGPT i fent recerca, per intentar evitar factors random que puguin intervenir. Les mesures són les següents:


- Abans de la part del codi corresponent al model, s'utilitza `random.seed(x)`, que fixa un punt d'inici `x` (el que es vulgui) per al generador de nombres aleatoris perquè totes les operacions "aleatòries" (barrejar, generar números, etc.) vagin sempre exactament igual cada cop que s'executi el codi.
- Quan es fa el codi del model, s'utilitza `model=KNeighborsClassifier(n_neighbors=k, n_jobs=1, algorithm="brute")`: `k` és el nombre de veïns a considerar per cada punt (fonamental per fer el model); `n_jobs=1` obliga a executar sempre les operacions en el mateix ordre; i l'algorisme `brute` s'utilitza perquè no conté cap estructura de dades complexa minimitzant fonts de variació numèrica. En canvi, altres algorismes, com ho són `kd_tree` com `ball_tree`, poden variar lleugerament el recorregut intern de l'arbre segons el hardware o l'arquitectura de memòria.

Aquests són tots els paràmetres que, per aquest model predictiu en concret, es va trobar que es podien controlar per intentar evitar aquest problema. En tot cas considero important especificar que els resultats que mostra el notebook són els obtinguts amb l'ordinador personal de l'alumne.

Ara sí que el següent pas ja va ser el de fer els models predictius corresponents. Per diferents conjunts de variables es va fer un bucle `for` per valors de 0 a 100 de `k` ("number of neighbors") senars, ja que els parells poden portar problemes amb aquest tipus de model predictiu al tractar-se d'una anàlisi qualitativa. Es van utilitzar 4 conjunts de dades diferents: el primer amb totes les variables, i llavors es van anar eliminant basant-ho en les variables que segons els coeficients de la Regressió Logística (notebook 'LogisticRegression') més afecten en l'abandonament. Ara bé, cada vegada que es feia una nova selecció de variables, tot i que d'entrada ens basàvem en els coeficients, si es veia que hi havia quelcom que no encaixava amb els resultats que havíem obtingut al llarg del projecte, es feia alguna modificació. Cal comentar, però, que la majoria de coeficients concordaven amb els resultats obtinguts.

Primer es va fer un nou conjunt de dades agafant les variables amb un coeficient d'ordre $10e-2$ o més gran (descartem els d'ordre $10e-3$), llavors un utilitzant només les variables amb un coeficient en valor absolut més gran o igual a 0.3, i finalment només amb les variables de coeficient més gran de 0.5 (més ja no perquè ens quedaríem amb masses poques variables, i durant tot l'estudi hem vist que no només 3 variables afecten a la taxa d'abandonament).

Els resultats, amb l'ajuda del ChatGPT, es van representar gràficament fent primer els gràfics on es veia l'exactitud del model en funció de `k` per cada un dels 4 conjunts de dades utilitzats, i llavors els gràfics que representen les matrius de confusió, els quals es mostren i s'expliquen a continuació.




Gràfics de l'exactitud en funció de la k pels diferents conjunts de dades

En els gràfics de dalt s'observa que per cap dels 4 el punt més alt és un pic puntual d'una sola 'k', sinó que més aviat sembla una tendència. Primer augmenta la exactitud molt ràpidament (tot i que pel SUBCONJUNT 2 sobretot no és tan ràpid) i llavors es manté més o menys constant a mesura que la 'k' segueix augmentant. En els gràfics de dalt a l'esquerra i de baix a la dreta sembla que hi hagi un pic però ho considerem vàlid ja que no és un pic ni molt exagerat ni d'un únic valor. I en el gràfic de baix a l'esquerra sobretot després d'aquesta exactitud màxima trobem que aquesta torna a disminuir, segurament degut a que a partir de llavors el nombre de valors veïns que s'agafen ja són massa grans i els resultats no són representatius.

Es pot veure també que a mesura que anem fent més petit el conjunt de variables que considerem per fer la predicció, millor exactitud té el model que obtenim. Per tant podem arribar a la conclusió de que els coeficients obtinguts a partir de la Regressió Logística (i que a més concorden bastant amb el que hem anat concluint al llarg del Projecte) semblen correctes ja que ens permeten obtenir exactituds millors. Ara bé, aquests valors d'exactitud no ho són tot per veure si els models són més o menys bons.

Les matrius de confusió ens ajudaran a veure si els valors que el model encerta són dels que no abandonen, dels que sí que ho fan, o bé d'ambdós casos:



En aquests 4 gràfics que representen les matrius de confusió, el que s'observa és:

- A dalt a l'esquerra, els que el model predeix que no abandonen que realment no ho fan.
- A dalt a la dreta, els que el model predeix que abandonen i que realment no ho fan.
- A baix a l'esquerra, els que el model predeix que no abandonen i que realment sí que abandonen.
- I a baix a la dreta, els que el model predeix que abandonen i que realment ho fan.

De tot el que s'ha vist fins ara se'n poden treure diferents conclusions interessants:

- Amb els gràfics d'exactitud en funció de 'k' hem vist que pel subconjunt de dades que li diem 3 s'obté la major exactitud. De fet a mesura que anem disminuint les variables del conjunt millor exactitud anem obtenint, tal com s'ha dit abans.

- Ara bé, com que el que ens interessa sobretot és predir els abandonaments, veiem que el subconjunt de dades que millor ho predeix és el que li diem "Subconjunt 1", i que el que ho predeix pitjor (tot i que és el que predeix millor els que no abandonen), és el propi Subconjunt 3. Amb el Subconjunt 2 i sobretot amb el de totes les variables (el de dalt a l'esquerra) s'obtenen resultats similars al Subconjunt 1, però ens quedem amb aquest últim perquè és el que predeix millor el que més ens interessa i a més la predicció pels que no abandonen tampoc és dolenta comparada amb els altres models.

Si considerem que la companyia, per tal de retenir clients que per característiques es predeix que podrien abandonar, els hi fa un preu més econòmic, anem a continuació a

analitzar amb quin dels 4 models hi podria haver millors resultats tant econòmics com de taxa d'abandonament (que volem que disminueixi). Cada model, dels clients que realment abandonen, una part predeix que no l'abandonen; i dels que no abandonen una part predeix que sí. Si la companyia vol evitar abandonaments fent preus més econòmics pels clients que predeixen que poden abandonar, obtenim:

- MODEL AMB TOTES LES VARIABLES: a 132 clients se'ls hi oferiria un preu més econòmic, sense que fos necessari realment (per tant, la companyia perdria diners oferint preus més barats a clients que igualment no abandonarien); i a 151 dels que realment abandonen no se'ls hi oferiria el nou preu. Per tant, ens interessa que aquests dos números siguin com més petits millor i que alhora el nombre de clients que abandonen predits correctament (223 en aquest cas) sigui el més alt possible, òbviament.
- SUBCONJUNT 1: a 125 se'ls hi oferiria el nou preu sense que fos necessari, a 149 dels que abandonen no, i a 225 dels que abandonen sí.
- SUBCONJUNT 2: a 113 se'ls hi oferiria el nou preu sense que fos necessari, a 160 dels que abandonen no, i a 214 dels que abandonen sí.
- SUBCONJUNT 3: a 84 se'ls hi oferiria el nou preu sense que fos necessari, a 183 dels que abandonen no, i a 191 dels que abandonen sí.

Dels 2 primers models (TOTES LES VARIABLES i SUBCONJUNT 1), està clar que el del SUBCONJUNT 1 és millor ja que tots els "números" que ens interessen són millors pel SUBCONJUNT 1, tot i que no per gaire. Havent descartat el model amb totes les variables, amb la resta podem veure que si el que interessa és que es perdin el mínim de diners possible degut al preu econòmic, el SUBCONJUNT 3 és el millor, però alhora és el model que podria evitar menys abandonaments. En canvi el SUBCONJUNT 1 segurament faria que es perdessin més diners oferint una oferta a clients que no abandonarien, però evitaria més abandonaments. El SUBCONJUNT 2 ofereix uns resultats que estan entre els del subconjunt 1 i els del 3. És a dir, aquí la companyia, si ho considerés oportú, hauria de buscar un preu rebaixat que fes que els beneficis (en mitjana) de tenir més clients que no abandonen, fossin més grans que les possibles pèrdues provocades per oferir una oferta no necessària a certs clients.

Per tant, en resum, es podria dir que si la companyia trobés aquest equilibri, el més lògic sembla que seria quedar-nos amb el model de predicció "k-nearest_neighbor_prediction" que predeix millor els abandonaments, és a dir, el model que utilitza el SUBCONJUNT 1 de variables amb una $k=79$.

Com a últim comentari de tot això, és evident que la companyia també hauria tenir en compte que si per evitar abandonaments decidissin per exemple, enviar correus o fer trucades als clients explicant motius pels que no haurien d'abandonar la companyia, això també podria comportar més abandonaments: alguns clients que s'ha predit que abandonen dels que realment no ho fan, es podrien cansar d'anar rebent correus o trucades de la pròpia companyia i acabar abandonant (tot i no tenir la intenció de fer-ho inicialment). Per tant, per un costat queda clar que un model predictiu pot ajudar a la companyia a evitar abandonaments, sí. Ara bé, s'han d'avaluar correctament tots els riscos i problemes que poden aparèixer a causa dels mètodes utilitzats, ja que sinó, sense voler, intentant evitar abandonaments en pots provocar encara més.

Per acabar, s'obtenen els valors de recall (proporció de positius reals que han estat correctament identificats), precision (proporció de prediccions positives que realment són positives), i exactitud (percentatge d'encerts totals), del model seleccionat (SUBCONJUNT 1, k=79). A partir d'aquests, s'obté també el f1-score (que en aquest cas, com es mostra a la taula de sota, és d'un 62% pels que abandonen i d'un 87% pels que no): és la mitjana harmònica entre precision i recall, i mesura l'equilibri entre aquestes dues:

$$f1\ score = 2 \frac{precision \cdot recall}{precision + recall}$$

i per aquest motiu és el paràmetre que utilitzarem per comparar més endavant els diferents models predictius utilitzats.

L'exactitud en els gràfics de Exactitud vs. k ja s'ha vist que és d'un 80.55%. La resta de paràmetres pel SUBCONJUNT 1 i k=79, són:

	precision	recall	f1-score	support
0	0.86	0.88	0.87	1035
1	0.64	0.60	0.62	374
accuracy			0.81	1409
macro avg	0.75	0.74	0.75	1409
weighted avg	0.80	0.81	0.80	1409

Taula: Classification Report pel model KNN amb el Subconjunt 1 de dades i una k=79.


3.5 Arbre de decisió

Un dels 3 models predictius que vam realitzar va ser el de l'arbre de decisió. Aquest algoritme funciona dividint les dades segons condicions jeràrquicament aconseguint així una mena d'arbre.

El primer que vam fer per a aquest model predictiu va ser com per als altres dos, passar les dades categòriques a numèriques i normalitzar-les, ja que la llibreria d'on provenen aquests models predictius solament permeten que les dades estiguin d'aquesta forma.

Després vam dividir les dades en les quals volíem predir que en aquest cas era ben fàcil perquè volíem predir l'abandonament i hi ha una columna on indica precisament això ("churn") i després en aquelles que volíem utilitzar per a la predicció (tota la resta de variables). Dintre d'aquestes també vam fer una divisió en les dedicades a l'entrenament del model i les dedicades al seu testatge. Justament en aquest punt ens va sorgir l'inconvenient que depenent de l'ordinador aquesta última divisió de les dades la feia diferent amb el que ens donaven resultats diferents i no ens permetia fer una comparació sòlida dels models. Per solucionar aquest inconvenient vam fer una única divisió des d'un ordinador i amb els dataframes obtinguts els vam exportar i vam utilitzar-los tots nosaltres important-los als nostres respectius notebooks.

Un cop ja teníem les dades dividides correctament, en el cas de l'arbre predictiu vam fer un primer model de prova amb els paràmetres per defecte, vam obtenir aquests resultats:




Amb una exactitud del 73,24% i una F1 (mitjana harmònica entre el recall i la precisió, mètrica ideal per a models amb desequilibri de classes com en el nostre cas, molt més fiable que l'exactitud) del 50,6%.

Veient el baix de les mètriques vam decidir anar provant els diferents paràmetres d'aquest tipus de model predictiu per veure així si podem augmentar-li el rendiment.

- Màxima profunditat ("max_depth")

El primer paràmetre que vaig provar va ser el de màxima profunditat el qual controla els nivells que pot tenir l'arbre, és a dir, la quantitat de bifurcacions que pot arribar a tenir. D'aquesta forma ens evita el sobreajustament (fenomen de l'arbre de decisió on es creen massa subdivisions i el model predictiu s'especialitza massa).

En funció de la màxima profunditat vam obtenir els següents valors.




Després de fer aquestes proves, com es pot veure, el valor òptim que vam trobar va ser de 6 i aquest ens puja l'F1 fins a 56,46%, per tant, havíem aconseguit una millora.


- Mínim de mostres per la divisió ("min_samples_split"):

El segon paràmetre que vam provar va ser el de "min_samples_split" que bàsicament és el nombre mínim de mostres que ha de tenir un node per dividir-se, per defecte són dos. Aquest també controla el creixement excessiu de l'arbre i que provoca sobreajustament.

Vam seguir el mateix procediment que amb el paràmetre anterior i, en primer lloc, vam provar el paràmetre sol i vam obtenir els resultats següents:



Vam trobar com a valor òptim el 202, però aquest pujava molt poc l'F1, per tant, vam decidir ajuntar aquest paràmetre amb l'anterior i amb el seu valor òptim ($\text{max_depth}=6$) per veure que passava. Els resultats van ser els següents:





I efectivament vam aconseguir una millora de l'F1 més important que en el cas de no afegir el max_depth.

- Nombre de característiques per fer la divisió ("max_features")

El següent paràmetre que vam provar va ser el de "max_features" que determina el nombre de característiques màximes a considerar per fer una divisió del node.

Vam fer com en el cas anterior, primer provar el paràmetre sol i després amb altres paràmetres ja trobats i amb els seus valors òptims (que en aquest cas són, max_depth=6, min_samples_split=202). Els resultats, respectivament, van ser els següents:




Veiem que mentre que el model predictiu amb únicament el paràmetre de "max_features" baixa l'F1 respecte a la màxima trobada en l'exemple anterior, el model en el qual combinem tots els paràmetres provats fins ara (el segon a la figura) augmentem considerablement el seu rendiment fins al quasi 60% de F1, amb un max_features=20. Per tant, un altre cop havíem aconseguit una millora del model.

- Pes de les classes ("class_weight"):

Per últim, vam provar un paràmetre anomenat "class_weight" que s'encarrega d'ajustar el pes que té cada classe. Aquest paràmetre a diferència dels anteriors funciona amb strings determinats, nosaltres vam utilitzar el "balanced" que és molt útil per equilibrar variables molt descompensades, com efectivament la nostra.

Els resultats obtinguts combinant el nostre paràmetre amb els anteriors amb els seus valors òptims (max_depth=6, min_samples_split=202 i max_features=20), ja que veient la tendència no tenia molt de sentit fer una primera prova sense cap paràmetre, va ser el següent:



Amb una F1 del 61,5%, millor que qualsevol prova anterior.

Comparant aquesta última versió del model amb la primera podem dir que hem aconseguit una important millora en el seu rendiment en general. Fent proves amb els paràmetres d'aquest tipus de model hem determinat una combinació de 5 d'ells (el restant que no apareix anteriorment és el "random_state" que fixa l'aleatorietat a l'hora de crear el model cada cop i permetent així que sigui igual la forma de crear l'arbre) que ha optimitzat el model, passant de tenir un 50,6% d'F1 a un 61,5%. També la millora important del model es pot veure en les matrius de confusió primera i la darrera, on la quantitat d'encerts positius (encerts d'aquells que abandonen l'empresa, fila 2, columna 2) ha augmentat bastant, de 193 a 307.

Cal dir que hi existeix uns quants més de paràmetres pel model d'arbre de decisió i que no hem afegit. Per exemple tenim el "min_samples_leaf" que ens determina el mínim nombre de mostres perquè el node sigui una fulla (no es divideixi més) o el "max_leaf_nodes" que limita el nombre màxim de fulles que pot tenir l'arbre. Després hi ha d'altres molt més complexos com el "ccp_alpha" que bàsicament és un coeficient que controla la "poda" de l'arbre, com major és més subarbres de l'arbre principal són eliminats. La raó per la qual no hem afegit aquests paràmetres és que hem provat tots ells de forma general i no incrementaven el rendiment.




Després d'haver optimitzat un primer model amb totes les variables del dataframe vam pensar que igual era bona idea, per aconseguir un encara major rendiment, crear nous

models predictius seleccionant les variables a utilitzar que podíem considerar més influents, seguint el criteri dels coeficients de la Regressió Logística explicat en l'apartat 3.4.

Vam fer un total de tres models predictius nous (3 seleccions de variables) i en tots ells vam posar com a paràmetres els trobats amb el primer model.

- La primera selecció que vam fer va ser d'aquells que tenien un coeficient d'ordre $10e-2$ o més gran.
- La segona selecció va ser amb aquells que tenien un coeficient en valor absolut més gran o igual a 0,3.
- L'última selecció va ser d'aquells que tenien un coeficient en valor absolut més gran de 0,5.

Els resultats obtinguts en els 3 models van ser els següents (ordenats de 2 a 4):



Les F1 de cada model van ser:

- Model 2 → 63,4%
- Model 3 → 60,3%
- Model 4 → 59,9%

Com es pot observar, amb el model 2 que té la selecció menys restringent vam aconseguir l'F1 més elevada i, per tant, el consideràrem el model més bo i el que a les conclusions utilitzarem per comparar-lo amb els altres tipus de models predictius.

Altres observacions importants respecte a aquest últim apartat són que pel que fa a seleccionar variables influents, en el model predictiu arbre de decisió funciona de la següent manera. Si prescindim de poques variables augmentem el seu rendiment, però ràpidament quan més augmentem el nombre de variables extretes disminuïm el mateix rendiment fins a arribar a ser pitjor que l'original.

4. Comparacions dels models predictius i altres conclusions

- Hem vist que factors com haver estat pagant quotes elevades durant molt de temps influeixen clarament en la decisió d'abandonar. El mètode de pagament també és important, especialment l'ús del xec electrònic, que augmenta la taxa d'abandonament, i en general, els mètodes no automàtics. Pel que fa a la demografia amb els tests estadístics hem vist que tenir parella s'associa amb una permanència més llarga, i tant els sèniors com els clients amb parella tendeixen a contractar més serveis.
- Amb tota aquesta informació i amb la que ja hem extret anteriorment i explicat en l'informe 2, podem explicar moltes relacions significatives entre les característiques dels clients. Hem vist que la composició familiar (tenir parella i dependents) és un factor molt associat a la permanència i abandonament baix. L'edat també té un paper rellevant: tot i consumir més serveis i tenir despeses més altes, els clients sèniors abandonen amb més freqüència que els no sèniors. Aquesta pot ser una de les raons per la que mètodes de pagament manual tenen un associat un abandonament més elevat, ja que normalment es troben més relacionats amb un perfil de client d'edat més avançada.
- **Comparació dels models predictius:** comparant models predictius a partir del f1-score explicat anteriorment (pels que sí que abandonen), veiem que, com era d'esperar, el model de la Regressió Logística (que és el més "senzill") arriba a donar un f1 del 57%, per darrere del 62% al que arriba el model k-nearest neighbor prediction i del 63.4% de l'arbre de decisió, que per números, sembla el millor.
- Cal destacar que la exactitud general d'un model predictiu no ho és tot: les matrius de confusió i els altres paràmetres que hem anat comentant com el recall, la precision o el f1-score són fonamentals per veure i entendre els punts forts i dèbils del model, ja que per exemple, en el nostre cas, no ens serveix un model que tingui una exactitud altíssima però que només encerti els que no abandonen quan els que ens interessa és predir els abandonaments. L'apartat 3.4 (model KNN) n'és un clar exemple d'això.
- Tot i intentar predir els abandonaments, la companyia ha de saber fer el balanç correcte a l'hora de saber quins mètodes aplicar per evitar el màxim nombre

d'abandonaments possibles però minimitzant possibles pèrdues i efectes secundaris negatius. A l'apartat 3.4 es parla d'això.

- En conclusió, la combinació de l'anàlisi exploratori amb creació de models predictius han reforçat les conclusions que havíem extret utilitzant altres tècniques d'anàlisi de dades. Variables com el tipus de contracte, la durada a l'empresa (*tenure*), el mètode de pagament i determinats serveis tenen un pes alt en la predicció d'abandonament. Això ens confirma que les relacions vistes prèviament son semblants a les que es els models han utilitzat per predir.

5. Repartiment de tasques

- **Jordi:** anàlisi utilitzant tests estadístics i les seves gràfiques; tractament de dades necessari per fer els models predictius; entrenament del model de la regressió logística
- **Aniol:** tractament de dades necessari per fer els models predictius; model predictiu k-nearest neighbors per predir els abandonaments dels clients de la companyia de telecomunicacions.
- **Oscar:** millora i aprofundiment de l'objectiu mesos d'estada-abandonament; objectiu influència del mètode de pagament en l'abandonament; model predictiu arbre de decisió per predir els abandonaments dels clients de la companyia de telecomunicacions.